


Informe del proyecto

PREDICCIÓN EXPLICABLE DEL RIESGO CARDIOVASCULAR A 10 AÑOS

Comparación entre WHO 2019, Regresión logística y Gradient Boosting



Luis Pérez Martínez

Julio 2026

ÍNDICE

1. Resumen ejecutivo.....	3
2. Introducción y objetivo del proyecto	4
3. Datos utilizados.....	6
4. Construcción de la variable objetivo.....	8
5. Preparación del dataset final.....	10
6. Análisis exploratorio	12
7. Modelos comparados	14
7.1 WHO 2019 Cardiovascular Risk Chart	14
7.2 Regresión logística.....	15
7.3 Gradient Boosting	15
8. Evaluación final en test.....	17
9. Comparación final de resultados	20
10. Conclusiones	24
11. Limitaciones del proyecto.....	25
12. Mejoras futuras.....	27
13. Bibliografía y herramientas utilizadas.....	29

ÍNDICE DE TABLAS

Tabla 1. Partición final del dataset tras la preparación de datos.11

Tabla 2. Resumen de métricas finales en test. 17

Tabla 3. Modelo ganador según criterio de evaluación. 20

ÍNDICE DE FIGURAS

Figura 1. Comparación de métricas principales en test. 18

Figura 2. Curvas ROC de los modelos en el conjunto de test. 19

Figura 3. Comparación de errores en test..... 21

Figura 4. Riesgo medio estimado según resultado real..... 22

Figura 5. Mapa de calor del rendimiento final por métrica..... 22

1. Resumen ejecutivo

Este proyecto tiene como objetivo estimar el riesgo de sufrir un evento cardiovascular a 10 años mediante la comparación de tres enfoques predictivos: un modelo clínico de referencia, un modelo estadístico interpretable y un modelo moderno de machine learning.

Para ello se utilizaron datos públicos y anonimizados procedentes de NHANES I y de su estudio de seguimiento NHEFS. A partir de estas fuentes se construyó una variable objetivo que identifica si cada participante presentó un evento cardiovascular durante los primeros diez años de seguimiento.

Los modelos comparados fueron WHO 2019 Cardiovascular Risk Chart, regresión logística y Gradient Boosting. Los tres modelos se evaluaron utilizando las mismas variables predictoras: edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Esta decisión permitió realizar una comparación justa entre los distintos enfoques.

El conjunto final de modelado estuvo formado por 3.246 participantes. De ellos, 2.596 se utilizaron para entrenamiento y validación interna, y 650 se reservaron para la evaluación final en test. El conjunto de test no se utilizó durante el entrenamiento, la selección de hiperparámetros ni la elección de umbrales, con el objetivo de obtener una evaluación final más realista.

Los resultados finales muestran que Gradient Boosting obtuvo el mejor rendimiento global en test. Fue el modelo con mejor ROC-AUC, Average Precision, Brier score, F1-score y balanced accuracy. Esto indica que fue el modelo con mejor capacidad general para ordenar a los participantes según su nivel de riesgo y ofrecer probabilidades de mayor calidad.

WHO 2019, por su parte, fue el modelo con mayor sensibilidad. Detectó el mayor número de eventos cardiovasculares reales y dejó el menor número de falsos negativos. Esto lo convierte en una alternativa especialmente interesante cuando el objetivo principal es identificar el máximo número posible de personas en riesgo.

La regresión logística mostró un comportamiento equilibrado y destacó por su interpretabilidad. Aunque no fue el modelo con mejor rendimiento global, permite explicar con claridad la relación entre cada variable y el riesgo estimado, lo que la convierte en una opción útil cuando la transparencia del modelo es prioritaria.

En conclusión, el modelo más competitivo en términos predictivos fue Gradient Boosting. Sin embargo, la elección final del modelo dependería del objetivo práctico: maximizar la detección de eventos, priorizar la interpretabilidad o buscar el mejor rendimiento predictivo global.

2. Introducción y objetivo del proyecto

Las enfermedades cardiovasculares representan uno de los problemas de salud más relevantes en el ámbito de la prevención sanitaria. Su detección temprana es especialmente importante, ya que permite identificar a personas con mayor riesgo y orientar mejor las decisiones relacionadas con el seguimiento, la prevención y el tratamiento.

En este contexto, los modelos predictivos pueden ser una herramienta útil para estimar la probabilidad de que una persona sufra un evento cardiovascular en el futuro. Aunque estos modelos no sustituyen una valoración médica real, sí permiten analizar patrones de riesgo, comparar distintos enfoques de predicción y comprender qué variables pueden estar más relacionadas con el desarrollo de eventos cardiovasculares.

Este proyecto se centra en la estimación del riesgo cardiovascular a 10 años. El objetivo principal es comparar tres enfoques diferentes: un modelo clínico de referencia, un modelo estadístico interpretable y un modelo moderno de machine learning.

Los modelos comparados son WHO 2019 Cardiovascular Risk Chart, regresión logística y Gradient Boosting. La finalidad es analizar si un modelo de machine learning puede mejorar el rendimiento predictivo frente a un modelo clínico establecido y frente a un modelo estadístico más sencillo e interpretable.

La pregunta principal del proyecto es la siguiente: ¿puede un modelo moderno de machine learning mejorar la capacidad de discriminación y la calidad de las probabilidades frente a un modelo clínico de referencia y un modelo estadístico interpretable?

Para responder a esta pregunta, los tres modelos se comparan utilizando la misma muestra, la misma variable objetivo y el mismo conjunto de variables predictoras. Las variables utilizadas son edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. De esta forma, la comparación entre modelos se realiza de manera más equilibrada y se evita que las diferencias de rendimiento se deban a que un modelo haya utilizado más información que otro.

El proyecto tiene un enfoque analítico y formativo. No pretende desarrollar una herramienta clínica definitiva, sino construir un flujo completo de análisis de datos aplicado a salud preventiva: desde la preparación de los datos y la construcción de la variable objetivo hasta la evaluación final de los modelos predictivos.

Además, el proyecto busca mostrar que la evaluación de un modelo predictivo no debe basarse únicamente en una métrica. Por ello, se analizan diferentes criterios, como la capacidad de discriminación, la calidad de las probabilidades, la sensibilidad, la especificidad, los falsos positivos, los falsos negativos, la calibración y la interpretabilidad.

De esta forma, la comparación final no se limita a elegir un único modelo ganador, sino que permite entender qué aporta cada enfoque. WHO 2019 sirve como referencia clínica, la regresión logística aporta interpretabilidad y Gradient Boosting permite evaluar el rendimiento de un modelo más flexible y complejo.

El objetivo general de este proyecto es construir y comparar tres enfoques de predicción del riesgo cardiovascular a 10 años, utilizando datos reales y variables clínicas básicas, para analizar qué modelo ofrece mejor rendimiento según distintos criterios de evaluación.

La pregunta central del análisis es si un modelo moderno de machine learning puede mejorar la predicción del riesgo cardiovascular frente a un modelo clínico de referencia y un modelo estadístico interpretable.

Los tres enfoques comparados son los siguientes:

WHO 2019 Cardiovascular Risk Chart, como modelo clínico de referencia.

Regresión logística, como modelo estadístico interpretable.

Gradient Boosting, como modelo moderno de machine learning.

El objetivo final es obtener una conclusión razonada sobre qué modelo resulta más adecuado según el criterio que se quiera priorizar: detectar el mayor número posible de eventos, mantener una interpretación sencilla o maximizar el rendimiento predictivo global.

3. Datos utilizados

Para el desarrollo de este proyecto se utilizaron datos procedentes de NHANES I y de su estudio de seguimiento NHEFS. NHANES I proporciona información inicial sobre características demográficas, hábitos de vida y variables clínicas de los participantes. Por su parte, NHEFS permite conocer la evolución posterior de esos individuos a lo largo del tiempo, incluyendo información relacionada con hospitalizaciones, mortalidad y tiempo de seguimiento.

La combinación de ambas fuentes permite construir un análisis longitudinal, ya que no solo se dispone de información inicial sobre cada participante, sino también de información posterior para comprobar si sufrió o no un evento cardiovascular durante los años siguientes. Esto resulta especialmente importante para un proyecto de predicción de riesgo, ya que el objetivo no es describir únicamente la situación inicial de los individuos, sino estimar la probabilidad de que ocurra un evento futuro.

El conjunto de datos inicial estaba formado por 14.407 participantes. A partir de esta base se identificaron los casos en los que era posible conocer si el participante había sufrido un evento cardiovascular durante los primeros diez años de seguimiento. Tras este proceso, se obtuvo un subconjunto de participantes con resultado conocido, diferenciando entre personas que presentaron un evento cardiovascular y personas que no lo presentaron durante ese periodo.

Para que la comparación entre modelos fuera coherente, el análisis se centró en participantes de entre 40 y 74 años. Esta restricción de edad se aplicó porque el modelo WHO2019 Cardiovascular Risk Chart trabaja con rangos de edad concretos y porque el objetivo era comparar todos los modelos bajo unas mismas condiciones. De esta forma, se evitó que cada modelo trabajara con poblaciones diferentes.

Las variables predictoras utilizadas en el proyecto fueron edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Se eligieron estas variables porque son factores de riesgo cardiovascular relevantes y porque permiten comparar un modelo clínico de referencia con modelos contruidos mediante técnicas estadísticas y de machine learning. Además, todas ellas son variables relativamente sencillas de interpretar, lo que facilita la explicación posterior de los resultados.

La variable edad representa la edad del participante en el momento inicial del estudio. La variable sexo se codificó diferenciando entre hombres y mujeres. El tabaquismo actual indica si la persona fumaba en el momento de la medición inicial. La presión sistólica recoge el nivel de presión arterial sistólica, una variable directamente relacionada con el riesgo cardiovascular. Finalmente, el índice de masa corporal se utilizó como medida general del estado corporal del participante.

Antes de construir los modelos, fue necesario revisar la disponibilidad y calidad de estas variables. Se eliminaron los registros que no contaban con la información necesaria para aplicar los tres enfoques comparados. También se excluyeron participantes con antecedentes cardiovasculares previos, ya que el objetivo del proyecto era estimar el riesgo futuro y no analizar personas que ya habían presentado una enfermedad cardiovascular antes del periodo de seguimiento.

Después de aplicar los criterios de selección y limpieza, el conjunto final utilizado para el modelado quedó formado por 3.246 participantes. De ellos, 384 presentaron un evento cardiovascular a 10 años y 2.862 no lo presentaron. Esto supone una distribución desbalanceada, ya que los eventos cardiovasculares representan una proporción menor del total de casos.

Este desbalance es habitual en problemas de predicción de eventos de salud, donde los casos positivos suelen ser menos frecuentes que los negativos. Por esta razón, en la evaluación de los modelos no se utilizó únicamente la exactitud general, sino también métricas más adecuadas para analizar la capacidad de detección de eventos, como la sensibilidad, la precisión, el F1 -score, el balanced accuracy y el número de falsos negativos.

Los datos utilizados permiten desarrollar un proyecto completo de predicción de riesgo cardiovascular a 10 años, partiendo de información clínica y demográfica inicial y evaluando posteriormente si los participantes sufrieron o no un evento cardiovascular durante el periodo de seguimiento. Esta estructura hace posible comparar distintos enfoques predictivos de forma realista y bajo una misma base de datos.

4. Construcción de la variable objetivo

La variable objetivo del proyecto se construyó para identificar si cada participante sufrió o no un evento cardiovascular durante los primeros diez años de seguimiento. Esta variable es la base de todo el análisis, ya que los tres modelos comparados intentan estimar la probabilidad de que ocurra dicho evento.

La variable creada se denominó **EVENTO_CV_10_ANIOS** y se codificó de forma binaria. El valor 1 indica que el participante presentó un evento cardiovascular dentro de los diez años posteriores a la medición inicial. El valor 0 indica que el participante no presentó ningún evento cardiovascular durante ese periodo y que, además, disponía de seguimiento suficiente para confirmar esta ausencia de evento.

Para construir esta variable se combinaron distintas fuentes de información procedentes del seguimiento del estudio. Por un lado, se utilizaron los registros de hospitalización relacionados con eventos cardiovasculares. Por otro lado, se incorporó la información de mortalidad cardiovascular. De esta forma, la variable objetivo no se basó únicamente en un tipo de evento, sino que integró tanto eventos hospitalarios como fallecimientos de causa cardiovascular.

El criterio utilizado fue considerar como evento cardiovascular cualquier caso en el que el participante presentara un evento cardiovascular hospitalario o una muerte cardiovascular dentro de los diez años posteriores al inicio del seguimiento. Si una misma persona aparecía en más de una fuente, se contabilizaba como un único participante con evento, evitando duplicar casos.

También fue necesario diferenciar entre participantes sin evento y participantes con información insuficiente. Una persona se consideró como caso negativo únicamente si no presentó evento cardiovascular y contaba con al menos diez años de seguimiento. En cambio, si no había evento registrado pero el seguimiento era inferior a diez años, el resultado no podía conocerse con seguridad. Estos casos se clasificaron como desconocidos y no se utilizaron para entrenar ni evaluar los modelos.

Este paso fue importante porque, en un problema de predicción a diez años, no basta con saber que una persona no tiene un evento registrado. También es necesario comprobar que fue observada durante tiempo suficiente. Si una persona solo fue seguida durante pocos años y no tuvo ningún evento, no se puede afirmar que no lo habría tenido antes de cumplir los diez años de seguimiento.

A partir del conjunto inicial de 14.407 participantes, se identificaron 1.249 personas con evento cardiovascular conocido dentro de los diez años de seguimiento. Además, 9.605 participantes fueron clasificados como casos negativos al no presentar evento y disponer de seguimiento suficiente. Por otro lado, 3.553 participantes quedaron como resultado desconocido debido a la falta de seguimiento suficiente para confirmar si habían sufrido o no un evento cardiovascular a diez años.

Tras este proceso, se obtuvo un conjunto de 10.854 participantes con resultado conocido. Este conjunto permitió diferenciar de forma clara entre personas con evento cardiovascular y personas sin evento cardiovascular durante el periodo analizado.

La construcción de la variable objetivo fue uno de los pasos más importantes del proyecto, ya que condiciona directamente la validez del análisis posterior. Una definición incorrecta del evento habría afectado al entrenamiento de los modelos y a la interpretación de los resultados. Por ello,

se priorizó una definición conservadora, en la que solo se utilizaron participantes con información suficiente para confirmar su resultado.

En resumen, la variable objetivo permitió transformar la información longitudinal del seguimiento en un problema de clasificación binaria. A partir de ella, los modelos podían aprender patrones asociados al riesgo cardiovascular y estimar la probabilidad de que un participante sufriera un evento cardiovascular en los diez años posteriores a la medición inicial.

5. Preparación del dataset final

Una vez construida la variable objetivo, el siguiente paso consistió en preparar el conjunto de datos definitivo que sería utilizado para entrenar y evaluar los modelos. Esta fase fue necesaria para asegurar que los tres enfoques comparados trabajaran con la misma información y bajo las mismas condiciones.

El primer criterio aplicado fue restringir el análisis a participantes de entre 40 y 74 años. Esta decisión se tomó porque el modelo WHO 2019 Cardiovascular Risk Chart trabaja con rangos de edad concretos y porque el objetivo del proyecto era comparar los tres modelos sobre una población común. De esta manera, se evitó que las diferencias entre modelos se debieran a que cada uno estuviera utilizando una muestra diferente.

Después de aplicar la restricción de edad, se seleccionaron únicamente las variables necesarias para el análisis. Las variables predictoras utilizadas fueron edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Estas variables se eligieron porque permiten aplicar el modelo WHO 2019 y, al mismo tiempo, construir modelos estadísticos y de machine learning comparables.

También se revisó la presencia de valores perdidos en las variables utilizadas. Los registros que no contaban con la información necesaria fueron excluidos del conjunto final, ya que no podían utilizarse de forma homogénea en los tres modelos. Este paso permitió trabajar con una base limpia y consistente.

Además, se excluyeron los participantes con antecedentes cardiovasculares previos. Esta decisión fue importante porque el objetivo del proyecto era predecir el riesgo de sufrir un evento cardiovascular futuro, no analizar personas que ya habían presentado una enfermedad cardiovascular antes del periodo de seguimiento. Para ello se utilizó una definición estricta de enfermedad cardiovascular previa.

Tras aplicar todos los criterios de selección, limpieza y exclusión, el conjunto final de modelado quedó formado por 3.246 participantes. De ellos, 2.862 no presentaron evento cardiovascular a 10 años y 384 sí presentaron evento cardiovascular. Esto supone que los eventos cardiovasculares representaron aproximadamente el 11,83 % del conjunto final.

La distribución de la variable objetivo muestra un claro desbalance entre clases. La mayoría de los participantes no presentó evento cardiovascular durante el periodo analizado, mientras que los casos positivos fueron menos frecuentes. Este desbalance es habitual en problemas de predicción de eventos de salud y debe tenerse en cuenta al evaluar los modelos.

Por este motivo, en fases posteriores no se utilizó únicamente la exactitud como métrica de evaluación. También se analizaron métricas más adecuadas para problemas desbalanceados, como la sensibilidad, la especificidad, el F1-score, el balanced accuracy, el número de falsos negativos y el número de falsos positivos.

Una vez definido el conjunto final, los datos se dividieron en entrenamiento y test. El conjunto de entrenamiento se utilizó para ajustar los modelos, realizar la validación interna y seleccionar los umbrales de clasificación. El conjunto de test se reservó exclusivamente para la evaluación final, evitando utilizarlo durante el entrenamiento o la selección de parámetros.

La división se realizó manteniendo la proporción de eventos cardiovasculares en ambos conjuntos. El conjunto de entrenamiento quedó formado por **2.596 participantes**, mientras que el conjunto de test quedó formado por **650 participantes**. Esta separación permitió evaluar

posteriormente si los modelos mantenían un buen rendimiento sobre datos no utilizados durante el proceso de entrenamiento.

En resumen, la preparación del dataset final permitió construir una base limpia, coherente y comparable para los tres modelos. Esta fase aseguró que la evaluación posterior se realizara sobre la misma población, con las mismas variables y con una separación clara entre los datos utilizados para entrenar y los datos utilizados para evaluar el rendimiento final.

Tabla 1. Partición final del dataset tras la preparación de datos.

Conjunto ▾	Participantes ▾	Variables predictoras ▾	Eventos ▾	No eventos ▾	Prevalencia del evento ▾
Entrenamiento	2596	5	307	2289	11,83%
Test	650	5	77	573	11,85%

Elaboración propia.

6. Análisis exploratorio

Una vez preparado el conjunto de datos final, se realizó un análisis exploratorio con el objetivo de comprender la distribución de la variable objetivo y estudiar la relación inicial entre las variables predictoras y el evento cardiovascular a 10 años.

El conjunto final de modelado estaba formado por 3.246 participantes. De ellos, 2.862 no presentaron evento cardiovascular durante los diez años de seguimiento, mientras que 384 sí presentaron un evento cardiovascular. Esto supone una prevalencia del evento del 11,83 %, lo que confirma que se trata de un problema con cierto desbalance entre clases.

Este desbalance debe tenerse en cuenta durante la evaluación de los modelos. Si se utilizara únicamente la exactitud general, un modelo podría obtener un resultado aparentemente alto simplemente clasificando a la mayoría de participantes como casos sin evento. Por este motivo, en fases posteriores se utilizaron métricas adicionales como sensibilidad, especificidad, precisión, F1-score, balanced accuracy y número de falsos negativos.

El análisis exploratorio mostró diferencias claras entre los participantes que presentaron un evento cardiovascular y los que no lo presentaron. En primer lugar, la edad fue una de las variables más relevantes. Los participantes con evento cardiovascular tenían una edad media superior a la de los participantes sin evento. En el grupo sin evento, la edad media fue de 54,63 años, mientras que en el grupo con evento fue de 61,26 años.

La tasa de eventos también aumentó de forma progresiva con la edad. En los grupos de menor edad, entre 40 y 49 años, la proporción de eventos se situó alrededor del 5 % o 6 %. Sin embargo, en los grupos de mayor edad el riesgo fue claramente superior. En el grupo de 65 a 69 años la tasa de eventos fue del 19,78 %, y en el grupo de 70 a 74 años alcanzó el 33,93 %.

La presión sistólica también mostró una relación clara con el evento cardiovascular. Los participantes con evento presentaron una presión sistólica media de 150,02 mmHg, frente a 136,97 mmHg en los participantes sin evento. Además, la proporción de eventos aumentó en los grupos con mayores niveles de presión arterial. En participantes con presión sistólica inferior a 120 mmHg, la tasa de eventos fue del 6,60 %, mientras que en aquellos con presión sistólica igual o superior a 180 mmHg alcanzó el 28,12 %.

El sexo también presentó diferencias relevantes. En el grupo de mujeres, la tasa de eventos cardiovasculares fue del 8,14 %, mientras que en el grupo de hombres fue del 16,25 %. Esto indica que, dentro de la muestra analizada, los hombres presentaron una mayor proporción de eventos cardiovasculares a 10 años.

El tabaquismo actual también se asoció con una mayor proporción de eventos. Entre los participantes no fumadores, la tasa de evento fue del 10,30 %, mientras que entre los fumadores actuales fue del 14,86 %. Aunque la diferencia no fue tan marcada como en la edad o la presión sistólica, el tabaquismo siguió mostrando una relación coherente con el riesgo cardiovascular.

El índice de masa corporal presentó una relación menos intensa que otras variables. Los participantes con evento tuvieron un IMC medio de 26,70, frente a 25,96 en los participantes sin evento. Aunque se observaron diferencias entre algunos grupos de IMC, su relación con el evento cardiovascular fue más débil en comparación con variables como la edad, la presión sistólica o el sexo.

El análisis de correlaciones confirmó esta primera interpretación. La variable más relacionada con el evento cardiovascular fue la edad, seguida de la presión sistólica, el sexo masculino, el

tabaquismo actual y el índice de masa corporal. En concreto, las correlaciones con el evento fueron de 0,23 para la edad, 0,18 para la presión sistólica, 0,13 para el sexo masculino, 0,07 para el tabaquismo actual y 0,05 para el IMC.

Estos resultados exploratorios muestran que las variables seleccionadas contienen información relevante para estimar el riesgo cardiovascular. La edad y la presión sistólica aparecen como los factores con mayor relación inicial con el evento, mientras que el sexo y el tabaquismo también aportan información útil. El IMC muestra una relación más moderada, aunque se mantuvo en el análisis por su relevancia como variable clínica y porque forma parte del conjunto de variables utilizado para comparar los modelos.

El análisis exploratorio permitió confirmar que el conjunto de datos presenta patrones coherentes con el objetivo del proyecto. Los eventos cardiovasculares son más frecuentes en participantes de mayor edad, con mayor presión sistólica, hombres y fumadores actuales. Esta fase permitió entender mejor la estructura de los datos antes de pasar a la comparación de modelos predictivos.

7. Modelos comparados

En este proyecto se compararon tres enfoques distintos para estimar el riesgo cardiovascular a 10 años: un modelo clínico de referencia, un modelo estadístico interpretable y un modelo moderno de machine learning. La comparación se realizó utilizando la misma muestra, la misma variable objetivo y el mismo conjunto de variables predictoras.

Los tres modelos utilizaron como variables de entrada la edad, el sexo, el tabaquismo actual, la presión sistólica y el índice de masa corporal. Esta decisión permitió comparar los modelos de forma equilibrada, evitando que uno de ellos tuviera ventaja por utilizar más información que los demás.

El objetivo de esta fase no fue únicamente identificar qué modelo obtenía mejores resultados, sino también comprender qué aporta cada enfoque. En problemas de salud, el rendimiento predictivo es importante, pero también lo son la interpretabilidad, la facilidad de aplicación y la capacidad para detectar correctamente a las personas con mayor riesgo.

Por este motivo, se seleccionaron tres modelos con características diferentes. WHO 2019 Cardiovascular Risk Chart se utilizó como referencia clínica. La regresión logística se utilizó como modelo estadístico interpretable. Gradient Boosting se utilizó como modelo de machine learning más flexible, capaz de captar relaciones no lineales entre las variables.

7.1 WHO 2019 Cardiovascular Risk Chart

El primer modelo utilizado fue WHO 2019 Cardiovascular Risk Chart. Este modelo se incorporó al proyecto como referencia clínica, ya que permite estimar el riesgo cardiovascular a partir de variables sencillas y habituales en el ámbito sanitario.

En este proyecto se utilizó una versión basada en variables clínicas básicas, sin necesidad de incorporar colesterol. Las variables utilizadas fueron edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Estas variables permiten asignar a cada participante una estimación de riesgo cardiovascular a 10 años.

La principal ventaja de este enfoque es que se trata de un modelo sencillo, interpretable y fácil de aplicar. No requiere entrenamiento con los datos del proyecto, sino que funciona a partir de una tabla de riesgo previamente definida. Esto lo diferencia de los otros dos modelos, que sí aprenden patrones directamente a partir de los datos disponibles.

Sin embargo, esta misma sencillez también supone una limitación. Al basarse en una estructura fija, el modelo tiene menos capacidad para adaptarse a las particularidades de la muestra utilizada. Por tanto, puede ser útil como referencia clínica, pero no necesariamente tiene por qué ser el modelo con mejor rendimiento predictivo en este conjunto de datos.

En el proyecto, WHO 2019 sirvió como punto de comparación frente a los modelos entrenados con los datos. Esto permitió analizar si los enfoques estadísticos y de machine learning podían mejorar la capacidad predictiva de un modelo clínico establecido.

7.2 Regresión logística

El segundo modelo utilizado fue la regresión logística. Este modelo se seleccionó por ser uno de los enfoques estadísticos más utilizados en problemas de clasificación binaria, especialmente cuando se busca combinar rendimiento predictivo e interpretabilidad.

La regresión logística estima la probabilidad de que ocurra un evento a partir de una combinación de variables predictoras. En este caso, el evento analizado fue la presencia de un evento cardiovascular a 10 años. El modelo aprende la relación entre cada variable y la probabilidad estimada de sufrir dicho evento.

Una de las principales ventajas de la regresión logística es que permite interpretar el efecto de cada variable sobre el riesgo. Por ejemplo, permite analizar cómo cambia la probabilidad estimada cuando aumenta la edad, cuando la presión sistólica es mayor, cuando el participante es hombre o cuando es fumador actual.

En este proyecto, la regresión logística se utilizó como modelo interpretable. Las variables continuas fueron escaladas para facilitar el entrenamiento, mientras que las variables binarias se mantuvieron como indicadores. La configuración final seleccionada utilizó regularización L2, con el objetivo de mejorar la estabilidad del modelo y reducir el riesgo de sobreajuste.

La regresión logística no es tan flexible como otros modelos de machine learning, ya que asume una relación más simple entre las variables y el resultado. Sin embargo, esta limitación también puede ser una ventaja cuando se busca transparencia. Por ello, su papel dentro del proyecto fue servir como punto intermedio entre el modelo clínico WHO 2019 y el modelo más complejo de Gradient Boosting.

7.3 Gradient Boosting

El tercer modelo utilizado fue Gradient Boosting. Este modelo se seleccionó como enfoque moderno de machine learning, con mayor capacidad para captar relaciones complejas y no lineales entre las variables predictoras y el evento cardiovascular.

Gradient Boosting construye un conjunto de árboles de decisión de forma secuencial. Cada nuevo árbol intenta corregir parte de los errores cometidos por los anteriores. De esta forma, el modelo va mejorando progresivamente su capacidad predictiva.

La principal ventaja de este enfoque es su flexibilidad. A diferencia de la regresión logística, Gradient Boosting no necesita asumir una relación lineal entre las variables y el riesgo. Esto puede ser útil en problemas de salud, donde el efecto de algunas variables puede depender de combinaciones o interacciones entre factores.

En este proyecto, el modelo Gradient Boosting se ajustó utilizando validación interna y búsqueda de hiperparámetros. La configuración final seleccionada buscó evitar el sobreajuste, limitando la complejidad de los árboles y controlando el proceso de aprendizaje.

Aunque Gradient Boosting puede ofrecer un mejor rendimiento predictivo, también es menos interpretable que la regresión logística. Por este motivo, en el proyecto no solo se evaluó su rendimiento mediante métricas, sino que también se analizó la importancia de las variables para comprender qué factores estaban influyendo más en sus predicciones.

En conjunto, los tres modelos permitieron comparar enfoques con características diferentes. WHO 2019 aportó una referencia clínica sencilla. La regresión logística aportó interpretabilidad estadística. Gradient Boosting aportó flexibilidad y capacidad predictiva. Esta comparación permitió analizar no solo qué modelo funcionó mejor, sino también qué tipo de modelo puede ser más adecuado según el objetivo práctico del análisis.

8. Evaluación final en test

La evaluación final se realizó sobre el conjunto de test, formado por 650 participantes. Este conjunto no se utilizó durante el entrenamiento, la validación interna, la selección de hiperparámetros ni la elección de umbrales. De esta forma, los resultados obtenidos en test permiten valorar el comportamiento de los modelos sobre datos no utilizados previamente.

Los tres modelos fueron evaluados sobre la misma muestra de test y utilizando las mismas variables predictoras: edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Esto permitió comparar los resultados en igualdad de condiciones.

La evaluación se realizó desde dos perspectivas. En primer lugar, se analizaron métricas probabilísticas, como ROC-AUC, Average Precision y Brier score. Estas métricas permiten valorar la capacidad de los modelos para ordenar correctamente a los participantes según su nivel de riesgo y la calidad de las probabilidades estimadas.

En segundo lugar, se analizaron métricas de clasificación, aplicando a cada modelo el umbral seleccionado antes de evaluar en test. En este caso se estudiaron métricas como sensibilidad, especificidad, F1-score, balanced accuracy, falsos negativos y falsos positivos.

Tabla 2. Resumen de métricas finales en test.

Modelo	ROC-AUC	Average Precisión	Brier score	Sensibilidad	Especificidad	F1-score	Balanced accurac	Falsos negativo	Falsos positivo
WHO 2019	0.7735	0.3588	0.0930	0.8571	0.5620	0.3350	0.7095	11	251
Regresión logística	0.7752	0.3501	0.0912	0.7792	0.6440	0.3519	0.7116	17	204
Gradient Boosting	0.7973	0.3854	0.0885	0.8052	0.6457	0.3626	0.7255	15	203

Elaboración propia.


La tabla resume el rendimiento final de los tres modelos sobre el conjunto de test. Gradient Boosting obtuvo el mejor resultado global en ROC-AUC, Average Precision, Brier score, F1-score y balanced accuracy. WHO 2019 destacó por alcanzar la mayor sensibilidad y el menor número de falsos negativos, mientras que la regresión logística mostró un comportamiento intermedio y equilibrado.

Los resultados muestran que Gradient Boosting fue el modelo con mejor rendimiento global en test. Obtuvo un ROC-AUC de 0,7973, superior al de WHO 2019 y al de la regresión logística. Esto indica que fue el modelo con mayor capacidad para ordenar a los participantes según su probabilidad de sufrir un evento cardiovascular.

Además, Gradient Boosting también obtuvo el mejor Average Precision, con un valor de 0,3854. Esta métrica es especialmente relevante en problemas desbalanceados, ya que se centra en el rendimiento del modelo sobre la clase positiva. En este proyecto, la clase positiva corresponde a los participantes que sufrieron un evento cardiovascular a 10 años.

En cuanto al Brier score, Gradient Boosting obtuvo el valor más bajo, con 0,0885. Dado que en esta métrica valores más bajos indican mejores probabilidades, este resultado sugiere que las probabilidades estimadas por Gradient Boosting fueron las de mayor calidad global en el conjunto de test.

Figura 1. Comparación de métricas principales en test.



Elaboración propia.

La figura permite comparar visualmente las métricas principales de los tres modelos en el conjunto de test. Gradient Boosting presenta el mejor comportamiento general, especialmente en las métricas relacionadas con la capacidad predictiva global y la calidad de las probabilidades.


A pesar de que Gradient Boosting fue el modelo más competitivo en términos globales, WHO 2019 obtuvo la mayor sensibilidad, con un valor de 0,8571. Esto significa que fue el modelo que detectó una mayor proporción de participantes que realmente presentaron un evento cardiovascular.

Este resultado es importante porque, en un problema de salud preventiva, los falsos negativos pueden ser especialmente relevantes. Un falso negativo representa a una persona que realmente sufrió un evento cardiovascular, pero que el modelo clasificó como no positiva. En este sentido, WHO 2019 fue el modelo más conservador y dejó únicamente 11 falsos negativos.

Sin embargo, esta mayor sensibilidad tuvo como contrapartida una menor especificidad y un mayor número de falsos positivos. WHO 2019 generó 251 falsos positivos, frente a 204 en la regresión logística y 203 en Gradient Boosting. Esto indica que detectó más casos positivos, pero también clasificó como de riesgo a más personas que finalmente no presentaron evento cardiovascular.

La regresión logística obtuvo resultados cercanos a los otros dos modelos, aunque no fue la mejor en la mayoría de métricas. Su principal valor dentro del proyecto no fue superar al resto en rendimiento global, sino ofrecer una alternativa interpretable y estable, capaz de explicar de forma sencilla la relación entre las variables predictoras y el riesgo cardiovascular.

Figura 2. Curvas ROC de los modelos en el conjunto de test.



Elaboración propia.

Las curvas ROC muestran la capacidad de discriminación de los tres modelos. Aunque las diferencias no son extremas, Gradient Boosting presenta la curva más favorable y el mayor valor de ROC-AUC en el conjunto de test.

En conjunto, la evaluación final en test muestra que Gradient Boosting fue el modelo con mejor rendimiento predictivo global. WHO 2019 fue el modelo más sensible y el que menos eventos dejó sin detectar. La regresión logística ofreció un equilibrio razonable entre rendimiento e interpretabilidad.

Por tanto, los resultados indican que no existe una única respuesta válida para todos los escenarios. Si el objetivo principal es maximizar el rendimiento predictivo global, Gradient Boosting es la opción más sólida. Si se prioriza detectar el mayor número posible de eventos cardiovasculares, WHO 2019 resulta especialmente interesante. Si se busca un modelo transparente y fácil de explicar, la regresión logística sigue siendo una alternativa útil.

9. Comparación final de resultados

La comparación final de resultados permite interpretar el comportamiento de los tres modelos desde una perspectiva global. En el apartado anterior se analizaron las métricas principales en el conjunto de test. En este apartado se resume qué modelo destaca según cada criterio y qué implicaciones tiene cada resultado.

Los resultados muestran que Gradient Boosting fue el modelo con mejor rendimiento global. Obtuvo los mejores valores en ROC-AUC, Average Precision, Brier score, F1-score, balanced accuracy, especificidad y falsos positivos. Esto indica que fue el modelo más competitivo cuando se considera el rendimiento general del sistema.

Sin embargo, WHO 2019 obtuvo la mayor sensibilidad y el menor número de falsos negativos. Este resultado es especialmente importante en un contexto de salud preventiva, ya que un falso negativo representa a una persona que realmente sufrió un evento cardiovascular, pero que el modelo no clasificó como caso de riesgo.

La regresión logística no fue el modelo ganador en la mayoría de métricas, pero mantuvo un comportamiento equilibrado. Su principal aportación dentro del proyecto fue la interpretabilidad, ya que permite explicar de forma sencilla cómo se relacionan las variables predictoras con el riesgo cardiovascular estimado.

Tabla 3. Modelo ganador según criterio de evaluación.

Criterio	Modelo ganador
Mayor ROC-AUC	Gradient Boosting
Mayor Average Precision	Gradient Boosting
Menor Brier score	Gradient Boosting
Mayor sensibilidad	WHO 2019
Mayor especificidad	Gradient Boosting
Mayor F1-score	Gradient Boosting
Mayor balanced accuracy	Gradient Boosting
Menor número de falsos negativos	WHO 2019
Menor número de falsos positivos	Gradient Boosting


Elaboración propia.

La tabla resume qué modelo obtuvo el mejor resultado en cada criterio de evaluación. Gradient Boosting fue el modelo ganador en la mayoría de métricas, mientras que WHO 2019 destacó en los criterios relacionados con la detección de eventos reales.

Desde el punto de vista de los errores, los modelos muestran comportamientos diferentes. WHO 2019 fue el modelo que dejó menos falsos negativos, con 11 casos. Esto significa que fue el modelo que menos eventos cardiovasculares reales dejó sin detectar. Sin embargo, también fue el modelo que generó más falsos positivos, con 251 casos.

Gradient Boosting obtuvo el menor número de falsos positivos, con 203, y mantuvo un número reducido de falsos negativos, con 15. La regresión logística presentó un comportamiento muy parecido en falsos positivos, con 204, aunque dejó más falsos negativos que los otros dos modelos, con 17.

Figura 3. Comparación de errores en test.




Elaboración propia.

La figura compara el número de falsos negativos y falsos positivos de cada modelo. WHO 2019 minimiza los falsos negativos, mientras que Gradient Boosting consigue el menor número de falsos positivos y mantiene un equilibrio más favorable entre ambos tipos de error.

Otra forma de comparar los modelos es analizar si asignan un mayor riesgo medio a los participantes que realmente sufrieron un evento cardiovascular. En este sentido, los tres modelos diferenciaron entre participantes con evento y sin evento, pero la separación fue más clara en los modelos entrenados con los datos.

WHO 2019 estimó un riesgo medio del 9,82 % en participantes sin evento y del 17,87 % en participantes con evento. La regresión logística estimó un riesgo medio del 10,62 % en participantes sin evento y del 22,67 % en participantes con evento. Gradient Boosting obtuvo la mayor separación, con un riesgo medio del 10,57 % en participantes sin evento y del 23,68 % en participantes con evento.

Figura 4. Riesgo medio estimado según resultado real.




Elaboración propia.

La figura muestra que los participantes que realmente sufrieron un evento cardiovascular recibieron, de media, un riesgo estimado superior en los tres modelos. La separación fue especialmente clara en Gradient Boosting, lo que refuerza su capacidad para distinguir entre perfiles de mayor y menor riesgo.

El mapa de calor permite resumir visualmente el rendimiento relativo de los modelos en las distintas métricas. Esta representación facilita identificar qué modelo domina en la mayoría de los criterios y en qué aspectos concretos destaca cada enfoque.

Figura 5. Mapa de calor del rendimiento final por métrica.



Elaboración propia.

El mapa de calor confirma que Gradient Boosting fue el modelo con mejor rendimiento global, ya que concentra los mejores resultados relativos en la mayoría de métricas. WHO 2019 destaca principalmente en sensibilidad y falsos negativos, mientras que la regresión logística mantiene un perfil intermedio.

En conjunto, la comparación final muestra que Gradient Boosting fue el modelo más sólido desde el punto de vista predictivo. Presentó la mejor capacidad de discriminación, la mejor calidad global de probabilidades y el mejor equilibrio entre sensibilidad y especificidad.

No obstante, WHO 2019 sigue siendo relevante cuando el objetivo principal es detectar el mayor número posible de eventos cardiovasculares. Su mayor sensibilidad puede ser útil en escenarios donde se prefiere reducir al máximo el número de casos de riesgo no detectados.

Por su parte, la regresión logística aporta valor por su interpretabilidad. Aunque no fue el modelo con mejor rendimiento global, permite explicar con claridad el efecto de las variables utilizadas y puede ser una alternativa adecuada cuando la transparencia del modelo es prioritaria.

Por tanto, la elección final depende del objetivo práctico. Si se busca el mejor rendimiento predictivo global, Gradient Boosting es la opción más adecuada. Si se prioriza la detección de eventos, WHO 2019 resulta especialmente útil. Si se necesita un modelo sencillo e interpretable, la regresión logística sigue siendo una alternativa razonable.

10. Conclusiones

El proyecto permitió comparar tres enfoques diferentes para la predicción del riesgo cardiovascular a 10 años: WHO 2019 Cardiovascular Risk Chart, regresión logística y Gradient Boosting. Cada uno de ellos aportó una perspectiva distinta: referencia clínica, interpretabilidad estadística y rendimiento predictivo mediante machine learning.

Los resultados finales muestran que Gradient Boosting fue el modelo con mejor rendimiento global en el conjunto de test. Este modelo obtuvo los mejores valores en métricas como ROC-AUC, Average Precision, Brier score, F1-score y balanced accuracy. Esto indica que fue el modelo con mayor capacidad general para ordenar correctamente a los participantes según su nivel de riesgo y para generar probabilidades de buena calidad.

Además, Gradient Boosting consiguió un equilibrio adecuado entre sensibilidad y especificidad. Aunque no fue el modelo que alcanzó la mayor sensibilidad, sí logró reducir el número de falsos positivos y mantener un número relativamente bajo de falsos negativos. Por ello, puede considerarse el modelo más sólido desde el punto de vista predictivo global.

Por otro lado, WHO 2019 destacó por su alta sensibilidad. Fue el modelo que detectó una mayor proporción de participantes que realmente sufrieron un evento cardiovascular y el que dejó el menor número de falsos negativos. Este resultado es especialmente relevante en un contexto de salud preventiva, donde no detectar a una persona con riesgo real puede tener consecuencias importantes.

Sin embargo, la mayor sensibilidad de WHO 2019 estuvo acompañada de un mayor número de falsos positivos. Esto significa que el modelo clasificó como positivos a más participantes que finalmente no presentaron un evento cardiovascular. Por tanto, su utilidad depende del contexto: puede ser especialmente interesante cuando se prioriza detectar el máximo número posible de casos de riesgo, aunque sea a costa de generar más alertas.

La regresión logística mostró un rendimiento intermedio, pero aportó una ventaja importante: la interpretabilidad. A diferencia de Gradient Boosting, permite explicar de forma sencilla cómo se relacionan las variables predictoras con el riesgo cardiovascular estimado. Esto la convierte en una alternativa útil cuando la transparencia del modelo es una prioridad.

En conjunto, el análisis confirma que no existe un único modelo óptimo para todos los escenarios. La elección depende del objetivo principal. Si se busca el mejor rendimiento predictivo global, Gradient Boosting es la opción más adecuada. Si se quiere maximizar la detección de eventos cardiovasculares, WHO 2019 resulta especialmente relevante. Si se prioriza la explicación clara del modelo, la regresión logística sigue siendo una opción sólida.

También se comprobó que las variables utilizadas contienen información relevante para estimar el riesgo cardiovascular. La edad, la presión sistólica, el sexo, el tabaquismo actual y el índice de masa corporal permitieron construir modelos capaces de diferenciar entre participantes con mayor y menor riesgo. Entre ellas, la edad y la presión sistólica destacaron como factores especialmente importantes.

Como conclusión general, el proyecto muestra que un modelo de machine learning puede mejorar el rendimiento predictivo frente a enfoques más tradicionales, pero también pone de manifiesto que la interpretabilidad y el objetivo práctico del análisis deben tenerse en cuenta antes de elegir un modelo final.

11. Limitaciones del proyecto

Aunque el proyecto permitió comparar tres enfoques diferentes para la predicción del riesgo cardiovascular a 10 años, es importante reconocer una serie de limitaciones que deben tenerse en cuenta al interpretar los resultados.

En primer lugar, el análisis se basa en datos observacionales procedentes de NHANES I y de su estudio de seguimiento NHEFS. Esto significa que los datos no fueron generados específicamente para este proyecto, sino que proceden de un estudio previo con sus propios criterios de recogida, variables disponibles y estructura de seguimiento. Por tanto, el análisis está condicionado por la información existente en estas fuentes.

Una segunda limitación está relacionada con la construcción de la variable objetivo. Para identificar los eventos cardiovasculares a 10 años fue necesario combinar información de hospitalizaciones y mortalidad cardiovascular. Aunque este procedimiento permitió construir una variable objetivo más completa, también depende de la calidad, codificación y disponibilidad de los registros originales.

Además, algunos participantes no pudieron ser clasificados como positivos o negativos porque no disponían de seguimiento suficiente para confirmar si habían sufrido o no un evento cardiovascular durante los diez años posteriores a la medición inicial. Estos casos fueron excluidos del modelado para evitar clasificaciones inciertas, pero esta decisión redujo el tamaño final de la muestra.

Otra limitación importante es que el conjunto final de modelado estuvo formado por 3.246 participantes, de los cuales 384 presentaron un evento cardiovascular a 10 años. Aunque esta muestra permitió entrenar y evaluar los modelos, el número de eventos positivos sigue siendo relativamente reducido en comparación con los casos sin evento. Este desbalance entre clases condiciona la evaluación y hace necesario interpretar las métricas con cautela.

También debe tenerse en cuenta que el proyecto utilizó un conjunto limitado de variables predictoras: edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal. Estas variables son relevantes y permiten comparar los tres modelos de forma equilibrada, pero no recogen toda la información que podría influir en el riesgo cardiovascular. Variables como colesterol, diabetes, tratamiento antihipertensivo, antecedentes familiares, nivel socioeconómico u otros indicadores clínicos podrían mejorar la capacidad predictiva.

Otra limitación es que WHO 2019 Cardiovascular Risk Chart se aplicó como modelo de referencia, pero no fue desarrollado específicamente para esta muestra. Por ello, su rendimiento puede verse afectado por diferencias entre la población original para la que fue diseñado y la población analizada en este proyecto.

En el caso de los modelos entrenados con datos, especialmente Gradient Boosting, existe siempre cierto riesgo de sobreajuste. Aunque se utilizaron técnicas de validación interna, separación train/test y control de hiperparámetros, ningún procedimiento elimina por completo la posibilidad de que el modelo se adapte parcialmente a las características concretas de la muestra utilizada.

Además, el proyecto se centró en una evaluación interna sobre un conjunto de test separado, pero no incluyó validación externa en otra base de datos independiente. Por tanto, los resultados obtenidos no deben interpretarse como una garantía de rendimiento en otras poblaciones o contextos clínicos.

Finalmente, este trabajo tiene una finalidad analítica y formativa. No debe entenderse como una herramienta médica lista para su uso real ni como un sistema de apoyo a decisiones clínicas. Para una aplicación práctica sería necesario realizar validaciones adicionales, revisar los criterios clínicos con especialistas y cumplir requisitos éticos, legales y regulatorios.

En resumen, las principales limitaciones del proyecto están relacionadas con la fuente de datos, la construcción de la variable objetivo, el tamaño de la muestra final, el desbalance entre clases, el número limitado de variables predictoras y la ausencia de validación externa. Aun así, el análisis permite construir una comparación razonada entre modelos y extraer conclusiones útiles sobre sus ventajas y diferencias.

12. Mejoras futuras

A partir del trabajo realizado, existen varias líneas de mejora que podrían desarrollarse en futuras versiones del proyecto. Estas mejoras permitirían ampliar el análisis, reforzar la validez de los resultados y acercar el proyecto a una aplicación más completa.

Una primera mejora sería incorporar nuevas variables predictoras. En este proyecto se utilizaron edad, sexo, tabaquismo actual, presión sistólica e índice de masa corporal para poder comparar los tres modelos de forma equilibrada. Sin embargo, el riesgo cardiovascular puede estar influido por muchos otros factores. Incluir variables como colesterol, diabetes, tratamiento antihipertensivo, antecedentes familiares, actividad física u otros indicadores clínicos podría mejorar la capacidad predictiva de los modelos.

Otra posible mejora sería trabajar con un mayor número de observaciones. Aunque el conjunto final de modelado permitió realizar una comparación completa, el tamaño de la muestra se redujo tras aplicar los criterios de edad, disponibilidad de variables, ausencia de enfermedad cardiovascular previa y seguimiento suficiente. En una futura versión, se podría intentar utilizar una base de datos más amplia o combinar distintas fuentes para aumentar el número de participantes y de eventos positivos.

También sería interesante realizar una validación externa. En este proyecto, los modelos se evaluaron sobre un conjunto de test separado, lo que permite obtener una estimación más realista que evaluar sobre los mismos datos de entrenamiento. Sin embargo, una validación externa en otra población independiente permitiría comprobar si los modelos mantienen su rendimiento fuera de la muestra utilizada.

Otra línea de mejora sería profundizar en la calibración de los modelos. Aunque se analizó la calidad de las probabilidades mediante el Brier score y gráficos de calibración, en futuras versiones podrían aplicarse técnicas específicas de recalibración, como Platt scaling o isotonic regression. Esto permitiría ajustar mejor las probabilidades estimadas, especialmente si el modelo se quisiera utilizar en un contexto de apoyo a la toma de decisiones.

También se podrían probar modelos adicionales. En este proyecto se compararon WHO 2019, regresión logística y Gradient Boosting, pero existen otros enfoques que podrían aportar información interesante, como Random Forest, XGBoost, LightGBM, modelos bayesianos o redes neuronales sencillas. La incorporación de nuevos modelos permitiría comprobar si el rendimiento de Gradient Boosting puede ser superado o si modelos más simples ofrecen resultados similares.

Otra mejora importante sería ampliar el análisis de interpretabilidad. En el proyecto se analizó la importancia de las variables, pero una futura versión podría incorporar técnicas más avanzadas como SHAP values o partial dependence plots. Estas herramientas permitirían entender con más detalle cómo influye cada variable en la predicción individual y cómo cambian las probabilidades estimadas según distintos perfiles de riesgo.

También sería útil desarrollar una pequeña aplicación interactiva. A partir del modelo final, se podría crear una herramienta sencilla en la que el usuario introdujera valores como edad, sexo, presión sistólica, tabaquismo e IMC, y recibiera una estimación del riesgo cardiovascular a 10 años. Esta aplicación podría servir como demostración del proyecto dentro de un portfolio profesional.

Otra posible mejora sería incorporar una explicación más orientada a negocio o gestión sanitaria. Por ejemplo, se podría analizar cómo cambiarían las decisiones según distintos umbrales de clasificación, cuántas personas serían derivadas a seguimiento preventivo y qué coste tendría aumentar la sensibilidad del modelo. Esto permitiría conectar mejor los resultados técnicos con decisiones reales.

Finalmente, una mejora relevante sería revisar el proyecto con apoyo clínico. Aunque el análisis se ha realizado desde una perspectiva de ciencia de datos, la interpretación médica de los resultados debería ser contrastada con profesionales sanitarios antes de plantear cualquier uso práctico. Esto ayudaría a validar mejor la definición de evento, la selección de variables y la interpretación de los modelos.

En resumen, las principales mejoras futuras serían incorporar más variables, ampliar la muestra, realizar validación externa, mejorar la calibración, probar nuevos modelos, profundizar en la interpretabilidad y desarrollar una aplicación sencilla. Estas ampliaciones permitirían transformar el proyecto en una herramienta más completa, robusta y útil desde el punto de vista analítico.

13. Bibliografía y herramientas utilizadas

Bibliografía

Centers for Disease Control and Prevention, National Center for Health Statistics. (s. f.). NHANES I (1971–1974). Recuperado el 28 de septiembre de 2026, de <https://wwwn.cdc.gov/nchs/nhanes/nhanes1/Default.aspx>

Centers for Disease Control and Prevention, National Center for Health Statistics. (s. f.). NHANES I Epidemiologic Follow-up Study (NHEFS). Recuperado el 28 de septiembre de 2026, de <https://wwwn.cdc.gov/nchs/nhanes/nhefs/>

World Health Organization. (2019, 2 de septiembre). WHO updates Cardiovascular Risk Charts. <https://www.who.int/news-room/detail/02-09-2019-who-updates-cardiovascular-risk-charts>

WHO CVD Risk Chart Working Group. (2019). World Health Organization cardiovascular disease risk charts: Revised models to estimate risk in 21 global regions. *The Lancet Global Health*, 7(10), e1332–e1345. [https://doi.org/10.1016/S2214-109X\(19\)30318-3](https://doi.org/10.1016/S2214-109X(19)30318-3)

Herramientas utilizadas

El proyecto se desarrolló principalmente en Google Colab, utilizando Python como lenguaje de programación principal. Esta herramienta permitió realizar la carga de datos, limpieza, transformación de variables, construcción de la variable objetivo, entrenamiento de modelos, evaluación de resultados y exportación de tablas y gráficos.

Para el tratamiento y análisis de datos se utilizaron librerías como pandas y NumPy. Estas herramientas permitieron manipular los conjuntos de datos, crear nuevas variables, revisar valores perdidos, calcular estadísticas descriptivas y preparar la base final de modelado.

Para la construcción y evaluación de los modelos se utilizó scikit-learn. Esta librería permitió entrenar la regresión logística y el modelo Gradient Boosting, realizar la división entre entrenamiento y test, aplicar validación interna, calcular métricas de evaluación y generar predicciones probabilísticas.

Para la visualización de resultados se utilizaron librerías de representación gráfica como Matplotlib y Seaborn. Con ellas se generaron los gráficos incluidos en el proyecto, como comparaciones de métricas, curvas ROC, gráficos de errores, análisis de calibración y mapas de calor de rendimiento.

También se utilizaron archivos exportados en formato CSV, Excel y PNG para documentar los resultados finales. Estos archivos sirvieron como base para incorporar tablas y figuras al informe final de forma ordenada y trazable.

También se utilizó ChatGPT como herramienta de apoyo durante el desarrollo del proyecto, principalmente para orientar la estructura del análisis, resolver dudas técnicas, revisar explicaciones, mejorar la redacción del informe y organizar la presentación de resultados. Los cálculos, tablas, gráficos y modelos incluidos en el trabajo se generaron a partir del proceso desarrollado en Google Colab con Python.

Finalmente, el informe se elaboró en Microsoft Word, integrando el texto explicativo, las tablas y las figuras generadas previamente durante el desarrollo del proyecto. El objetivo fue presentar los resultados de forma clara, profesional y comprensible.